

Week 4 作业报告

问题 1 — 选择正确的基因组检测方法（25 分）

1. AI 介入前推理

RNA-seq 只告诉我 Gene X 在疾病组比对照组高，但转录本变多本身不是机制。要弄清楚为什么变高，得先猜调控异常大概出现在哪一层：可能是顺式调控区本身有变异，可能是染色质、组蛋白或 DNA 甲基化这类表观层面的问题，也可能是增强子和启动子之间的联系变了。

我打算先做 ATAC-seq。倒不是觉得它万能，而是它能在同一批病例和对照上直接看出 Gene X 附近染色质开不开，还能顺带判断候选位点是启动子区还是远端增强子；而且它便宜、要的细胞少，冻存细胞核也能用。做完它再决定下一步，比一上来把所有检测都排一遍划算。

但我清楚 ATAC-seq 的边界：它只回答“哪里开”，回答不了哪个转录因子结合、元件上是什么组蛋白修饰、CpG 甲没甲基化，更证明不了这个元件真的和 Gene X 启动子拉上了关系。所以我事先排了个顺序：ATAC 先定位候选元件；出来的峰看着像活性增强子，就接着做 H3K27ac CUT&Tag；怀疑有顺式变异就上 WGS/WES；启动子甲基化确实不一样就做 WGBS/EM-seq；调控看着像远端就加 Hi-C 或 Micro-C；最后用 MPRA 看这个元件（或某个等位基因）够不够驱动表达，用 CRISPRi 或直接删除看它原位是不是必需。后面每一步该不该做，由上一步的结果说了算，而不是一次把检测都堆上去。

2. AI 辅助工作流

我让 AI 批判、而不是替代我的设计（plan-first 提示词）：

"I have RNA-seq showing Gene X significantly upregulated in disease vs control. My design: start with ATAC-seq on the same samples, then branch: H3K27ac CUT&Tag if an active-looking peak appears; WGS/WES if a candidate variant is suspected; WGBS if promoter methylation differs; Hi-C if regulation looks distal; finish with MPRA and CRISPR perturbation. Critique this design: (a) what can each assay measure and what can it NOT prove; (b) where is my decision tree wrong or incomplete; (c) what order would you use, and why?"

我经核实后采纳的 AI 意见：（i）ATAC-seq 报告的是可及性，**不是** TF 身份或组蛋白状态——不能把一个峰过度解读为“TF 结合”；（ii）顺式调控变异无法由 ATAC-seq 单独检出——WGS 才是分型层面，杂合状态下等位基因特异的 ATAC 信号可以提示变异效应；（iii）Hi-C 环是群体平均，可能先于功能而存在——接触本身不是调控的证据；（iv）MPRA 在脱离基因组环境处检验增强子活性（充分性），而 CRISPRi 在原位检验必要性——两者回答不同问题，应当配对使用。

3. 验证（权威来源）

我把主要建议与权威来源核对，并据此修订了两处（补上明确的 WGS 分型分支；组蛋白谱检测改用适合低起始量的 CUT&Tag）：

表 1 Q1 验证来源与核对结果

主张	核对的来源	确认 / 修订
ATAC-seq = Tn5 可及的开放染色质	Buenrostro 等 2013, <i>Nat Methods</i> 10:1213 (doi:10.1038/nmeth.2688)	确认：测定可及性；不报告 TF 身份或组蛋白状态
CUT&Tag 适合低起始量组蛋白谱	Kaya-Okur 等 2019, <i>Nat Commun</i> 10:1930 (doi:10.1038/s41467-019-09982-5)	确认：抗体锚定 Tn5、低背景 → H3K27ac 用它
H3K27ac 标记活性（而非静息）增强子	Creyghton 等 2010, <i>PNAS</i> 107:21931 (doi:10.1073/pnas.1016297108)	确认：以 H3K27ac 作为活性增强子读出是合理的
CAGE 检测启动子/增强子转录起始	Andersson 等 2014, <i>Nature</i> 507:455 (FANTOM5 增强子图谱)	确认：双向加帽转录本标记活性增强子；CAGE ≠ 接触或因果
MPRA = 平行报告基因检验增强子活性	Melnikov 等 2012, <i>Nat Biotechnol</i> 30:271	确认：检验的是（游离质粒情境下的）充分性
CRISPRi 系统绘制功能性增强子-基因连接	Fulco 等 2016, <i>Science</i> 354:769 (CRISPRi-FlowFISH)	确认：检验的是内源位点的必要性

4. 最终结论

约 200 词说明。 ATAC-seq 测定染色质对 Tn5 的开放程度——它是潜在调控活性的指标，但无法说明哪个转录因子结合、元件上修饰了哪种组蛋白、CpG 是否甲基化、或该元件是否物理接触 Gene X 启动子。H3K27ac CUT&Tag/ChIP-seq 测定特定组蛋白修饰，能区分活性与静息增强子，却无法证明被标记的元件调控的是 Gene X 而非邻近基因。WGBS/EM-seq 以单 CpG 分辨率定量 DNA 甲基化，但甲基化往往只是许可性而

非指令性，也说明不了染色质状态。CAGE/RAMPAGE 捕获转录起始与增强子 RNA，是强的活性读出，但不是起因。Hi-C/Micro-C 报告的是平均三维邻近度，环可以存在而无功能。RNA-seq 给出我们要解释的表型。因此这些检测相互补充：可及性 + 组蛋白状态 + 甲基化 + 接触共同定位与刻画元件（相关性）；WGS 分型候选变异；而 MPRA 与 CRISPR 扰动检验功能——先检验元件（或等位基因）能否驱动活性，再检验它在基因组中是否必需。任何单层都不充分，机制只有在描述性、遗传性与功能性证据结合时才浮现。




图 1 Q1 检测策略工作流程图

生物学问题决定检测方法，因为表达变化背后的机制，只能用测定该特定层面的检测来检验（变异→WGS，可及性→ATAC-seq，组蛋白状态→H3K27ac，甲基化→WGBS/EM-seq，接触→Hi-C，活性→CAGE/MPRA，因果→CRISPR），而单一检测无法覆盖所有层面。

问题 2 — 从 FASTQ 到可信分析 workflow (25 分)

1. AI 介入前推理

让 AI 帮我设计流程之前，我先自己把场景定下来：demo 里的 S01 是 WGS，按胚系变异 calling 来做；但样本清单里还有 RNA-seq、ATAC-seq、ChIP-seq，所以主流程

里哪些步骤是检测特有的，我得自己标清楚。我先在纸上画了个 8 步的流程，每步是干什么的：

- FASTQ 质控——先看数据本身行不行，接头、质量崩、污染、异常重复都在这里暴露。
- 选参考基因组——全流程对齐到同一版本，注释版本要和参考匹配。
- 比对——reads 回贴到基因组上；RNA-seq 这一步得用剪接感知的比对器。
- 比对后处理——去 PCR 重复、碱基质量重校准，不然技术噪音会被当成变异。
- 检测特异的下游分析——WGS 出变异、RNA-seq 出计数、ATAC/ChIP 出峰。
- 注释——给变异加上后果、人群频率、临床意义。
- 可视化——自己过一遍图，找伪影、批次效应和异常点。
- 解读——回答最初的生物学问题，前面所有步骤最后都是为这一步服务的。

我给自己定的规矩是：先把步骤、目的、软件、输出格式和 QC 阈值都想清楚，再让 AI 给具体命令；阈值这种东西我自己选、自己核，不能图省事让 AI 替我定。

2. AI 辅助 workflow

Plan-first 提示词：

"Design a complete WGS analysis workflow from paired-end Illumina FASTQ to annotated variants, for a small human cohort, using GRCh38. Do not write commands yet — first give me the ordered steps, the purpose of each, the key software, and the file formats produced at each step. Then, for the QC step only, propose concrete FastQC metrics to inspect and a trimming strategy."

我保留了 AI 的建议：每文件 FastQC + MultiQC 汇总；fastp 去接头/低质量修剪并加“修剪后重检”回环；BWA-MEM 比对并加 read group；Picard/GATK MarkDuplicates + BQSR；GATK HaplotypeCaller 以 GVCF 模式 + 联合分型；VEP 注释；IGV + MultiQC 复核。计划定稿后我才请 AI 给出具体命令，并独立复核了每个参数（见下）。

3. 验证（权威来源）

对照官方文档逐条核对：

表 2 Q2 AI 审计表（AI 建议 / 我的验证 / 最终决定）

AI 建议	我的验证（文档 / 来源）	最终决定
用 BWA-MEM 比对	BWA-MEM 是 GATK Best Practices 胚系 workflow 推荐的比对器（ gatk.broadinstitute.org ）；已确认 -R read group 语法及 SAM→BAM→排序流程	采纳 —— WGS/ATAC/ChIP 用 BWA-MEM（或 BWA-MEM2）；RNA-seq 用 STAR

AI 建议	我的验证（文档 / 来源）	最终决定
用 GRCh38（hg38）	Schneider 等 2017：相比 GRCh37，GRCh38 提升 SNP/indel 的召回率与精确率；含 decoy/alt 重叠群可减少假比对	采纳 —— GRCh38 primary 组装 + 配套 GENCODE 注释；全程不混用版本
HaplotypeCaller（GVCF）+ 联合分型	GATK HaplotypeCaller 在活跃区域做局部从头组装，是胚系短变异的标准方法（GATK 官方文档）	采纳 —— 单样本 GVCF，队列联合 calling
WGS 需要 MarkDuplicates	Picard/GATK MarkDuplicates 是 GATK Best Practice；PCR 重复会偏倚等位基因计数	对 WGS/ATAC/ChIP 采纳 ；RNA-seq 定量时保留重复（按文库分子计数）—— 这是我否决的 AI 默认项
calling 前做 BQSR	BQSR 属于 GATK Best Practices，用于建模系统性碱基错误；需 known-sites VCF	采纳并记录 known-sites 资源版本；小队列视为“可选但推荐”
10 个样本用 VQSR	VQSR 需要大规模训练集（GATK 建议至少 30 个外显子组或 30 个全基因组）—— 不适合极小队列	否决 —— 改用硬过滤（QD、FS、MQ、ReadPosRankSum），并在工作流中说明

FastQC 指标（依据 `data/demo\_fastq/fastqc\_snapshot.tsv`，并与原始 demo FASTQ 交叉核对）：

表 3 Q2 FastQC 指标解读（依据 fastqc_snapshot.tsv 并与原始 demo 数据核对）

指标	我检查什么	解读
碱基质量（Per-base quality）	各循环中位 Phred；末端崩溃	WARN —— 约 15% 的 R1 在循环 50 后中位 Phred 降至约 12（植入的质量崩溃；我扫描原始 FASTQ 确认了下降）。处理：3' 端修剪（fastp / Trimmomatic TRAILING）和/或长度过滤；重跑 FastQC。
GC 含量（Per-sequence GC）	单峰分布，与基因组相符（人类约 41%）	WARN —— 主峰约 41% 之外还有一个高 GC 肩峰（约 78%），约 10% 的 reads 属于污染 spike（原始数据确认）。处理：用 FastQ_Screen / BLAST 鉴定来源；比对前排除或去污染。

指标	我检查什么	解读
接头含量 (Adapter content)	接头比例是否在读段末端上升	FAIL —— Illumina 样接头 AGATCGGAAGAGC 出现在约 15% 的 paired reads 中 (确认: 120 条中 18 条)。处理: 接头修剪 (fastp 自动检测 / cutadapt), 随后重检。
重复水平 (Duplication levels)	重复是否与检测类型相符	WARN —— 一条模板序列在 R1 中重复约 15% (确认 18/120 条完全相同)。处理: WGS 标记重复; RNA-seq 不合并。
过表达序列 (Overrepresented seqs)	只应有已知/可解释的 kmer	FAIL —— 接头片段占据过表达 kmer 首位; 与接头含量一致。处理: 修剪 + 重检, 确认无 rRNA/引物残留。
N 含量 (Per-base N)	各循环约 0% N	PASS —— 无 basecalling 崩溃。
长度分布 (Length distribution)	与预期读长一致	PASS —— 所有 reads 均为 80 bp (已确认)。

快照与实际 demo 数据一致 (120 条 PE、80 bp; 15% 接头; 高 GC spike; 重复模板), 所以我的解读不是凭快照“信以为真”。

4. 最终结论

最终工作流 (见下图): FASTQ → 质控 (FastQC/MultiQC + 修剪 + 重检) → GRCh38 参考基因组 → 比对 (BWA-MEM / STAR) → 处理 (MarkDuplicates、BQSR、索引) → 检测特异性下游 (HaplotypeCaller / 定量 / 峰 calling) → 注释 (VEP / ANNOVAR) → 可视化 (MultiQC、IGV、bigWig) → 解读。可复现性内建其中: 每个工具版本、参考/注释版本和参数都记录在案, 每个结果都能追溯到原始 FASTQ。




图 2 Q2 分析工作流程图

分析者（而非 AI）负责： 选择参考/注释组合并保持一致；对照实际数据验证每个参数（读 FastQC 图，而不只是看汇总一行）；决定如何处理 QC 失败（修剪 vs 丢弃 vs 重测序）；判断 VQSR/硬过滤是否适用于当前队列规模；检查批次效应与多重检验校正；最终解读生物学意义——AI 提出命令，但决定与可复现性由分析者承担。

问题 3 — 整合多组学证据提出调控假设（25 分）

1. AI 介入前推理

在把五层数据放在一起看之前，我逼着自己先一层一层单独读——因为“几个组学都支持”很容易把每层证据各自的弱点盖过去。

ATAC-seq 上这个候选区有一个很清楚的 Tn5 峰，这只能说明它染色质是开的，至于这是个什么元件、结合了什么转录因子、管的是哪个基因，它都答不上来。H3K27ac 在这个峰上信号很强，符合活性增强子的样子，但“带着这个标记”和“真的在干活”是两回事，它也不告诉我靶基因是谁。元件里的 CpG 甲基化很低，说明这个区域是允许活跃的，但低甲基化在很多跟调控无关的地方也能看到，而且说不定它是表达之后的结果，不是原因。Hi-C/Micro-C 显示这个区域和 Gene Y 启动子有接触，看起来像个增强子-启动子环，但 Hi-C 测的是一群细胞的平均接触，有接触不代表有调控。最后 RNA-seq 只说明 Gene Y 在这个条件下是转录的，我没法把表达归功于这个候选元件头上。

把这五层拼起来，我现在的初步想法是：这个候选区域很可能是 Gene Y 的一个活性增强子——它开着、带 H3K27ac、低甲基化、和 Gene Y 启动子接触，而 Gene Y 确实在表达。但几个我解释不了的地方也摆在那儿：这个环也可能连的是同一个 TAD 里的其他基因；数据是混合样本，这些标记说不定来自样品里的别的细胞；而且没有任何一层能单独证明因果。所以后面必须上 CRISPRi 这类功能实验，才能把相关和因果分开。

2. AI 辅助工作流

要求 AI 区分证据类别的提示词：

"For a candidate enhancer upstream of Gene Y I have five data layers (ATAC-seq, H3K27ac, DNA methylation, Hi-C/Micro-C, RNA-seq) from the same condition. Separate, for each layer: (1) what is the *direct observation*; (2) what is a *biological interpretation*; (3) what *evidence is missing* to connect this layer to regulation of Gene Y. Then propose the strongest *alternative explanation* to 'it is Gene Y's enhancer' and one *functional experiment* that distinguishes correlation from causality."

AI 对观察/解读的区分与我的大体一致；它补充的有用点：（i）Hi-C 环是群体平均、混合细胞类型的观察——单细胞/捕获 Hi-C 或 HiChIP 可以加强；（ii）远端元件

上的 H3K27ac 与增强子功能相关而非证明——元件可以带标记却可有可无；（iii）最强的替代解释是：该元件调控同一 TAD 内的另一个基因，Gene Y 共表达只是巧合。我对照增强子/CRISPRi 文献核实了这些框架（见下）并保留。

3. 验证（权威来源）

- H3K27ac 区分活性与静息增强子：Creyghton 等 2010，*PNAS* 107:21931（doi:10.1073/pnas.1016297108）。
- CRISPRi-FlowFISH 系统绘制功能性增强子-基因连接及 activity-by-contact 模型：Fulco 等 2016，*Science* 354:769（doi:10.1126/science.aag2446）；Nasser 等 2021，*Nat Genet* 53:354（ABC 模型——增强子活性 × 接触预测基因调控）。两者都证实：接触 + 活性标记能预测，但扰动才能证明。
- Micro-C 以高分辨率解析短距离接触：Hsieh 等 2020，*Mol Cell* 78:493。

4. 最终结论

替代解释： 该元件是同一 TAD 内另一个基因（或一个未被注释的反义/长链非编码 RNA 转录本）的活性增强子，Gene Y 共表达是巧合——例如两者受同一个上游转录因子调控，或 Hi-C 接触反映的是先存的结构性环而非调控性环。这个替代解释与数据一致，因为可及性、H3K27ac 与低甲基化都是增强子的一般特征，并不编码靶基因身份；Hi-C 接触本身也不能证明 Gene Y 是功能靶基因。

功能实验（因果性）： 在候选元件处做 CRISPRi（dCas9-KRAB + 针对该元件的 2–3 条 sgRNA，在与组学数据相同的细胞类型中进行）。

- 扰动什么：候选增强子的内源活性（KRAB 沉积 H3K9me3，沉默该元件）。
- 若增强子对 Gene Y 有因果作用：Gene Y 表达显著下降（Fulco 2016 式读出），同一 TAD 内无关基因不变。
- 若替代解释成立：Gene Y 表达不变，取而代之的是替代靶基因（或邻近转录本）下降。
- 关键对照：非靶向 sgRNA；一条已知不调控 Gene Y 的增强子（阴性对照）；每个元件两条独立 sgRNA 排除脱靶；测量 TAD 内多个基因以显示特异性。

约 200 词整合解读。 综合来看，各层证据与“活性增强子”模型相互一致：元件可及（ATAC）、带活性增强子标记（H3K27ac）、许可性低甲基化、与 Gene Y 启动子物理接触（Hi-C/Micro-C），且同一条件下 Gene Y 有表达。每一层都独立支持潜在调

控，但没有一层——包括接触——能确立该元件 导致 Gene Y 表达：可及性与 H3K27ac 是许多可有可无或调控其他基因的增强子的共同特征；甲基化可能是下游后果；Hi-C 环是群体平均，可能是结构性而非调控性；RNA-seq 本身无法把因果归属到某个特定元件。因此整合假设是：这是 Gene Y 的一个合理活性增强子，其强度来自五条独立证据线的汇聚——而决定性检验是扰动：在恰当对照下沉默该元件后 Gene Y 表达是否改变，以排除同一 TAD 内另一基因共调控的可能。




图 3 Q3 位点调控链图

该候选元件通过 作为同一条件下可及、带 H3K27ac 标记、低甲基化并与 Gene Y 启动子接触的活性增强子 来调控 Gene Y；这可以通过 在候选元件处做 CRISPRi (dCas9-KRAB) 并测量 Gene Y 及同一 TAD 内对照基因的表达 来检验。

问题 4 — AI 辅助变异优先级排序（25 分）

1. AI 介入前推理

让 AI 帮我写代码之前，我先把优先级的逻辑自己定下来。想法很简单：技术上不可信的变异直接扔掉（硬排除），剩下的再按价值排队（软降权）；判断顺序上，call 可不可信永远排在稀有性和功能后果前面，临床标签放最后。具体标准见下表：

表 4 Q4 变异过滤逻辑（AI 介入前自行定义）

标准	规则 / 阈值	理由
FILTER	仅 == PASS	LowQual/FAIL 说明比对或 calling 不可靠

标准	规则 / 阈值	理由
深度 (DP)	≥ 20	胚系变异低于约 20 $\times$, 基因型不可信
基因型质量 (GQ)	≥ 30	<30 意味着基因型至少有约 1% 出错概率
等位基因频率 (AF)	≤ 0.01	稀有变异才符合孟德尔病假说; 严重表型致病位点不可能是常见等位基因
后果	高/中影响: 剪接、错义、终止、移码	最可能改变 RNA 或蛋白功能
ClinVar / 临床注释	Pathogenic > 冲突/VUS > 可能良性 > 良性	临床证据重要, 但合成标签必须复核
基因/表型相关性	基因与表型相关	TP53、BRCA2、MSH2 等是已确立疾病基因, 但需表型匹配

按这个顺序筛: 技术 QC $\rightarrow$ 深度和 GQ $\rightarrow$ 人群频率 $\rightarrow$ 后果类型 $\rightarrow$ 临床注释 $\rightarrow$ 基因和表型是否匹配。筛之前我就给自己打了预防针: MSH2 的 stop_gained 和 MECP2 的 frameshift 虽然注释写得吓人, 但 QC 不过关就必须扔掉; 反过来, F5、ATM 这些在人群里常见的变异, 哪怕基因是疾病基因, 也不能当成严重单基因病的致病变异来解释。AI 可以帮我把这套流程写成代码, 但阈值和顺序是我定的, 它不能动。

2. AI 辅助 workflow

Plan-first 提示词:

"Plan a variant-prioritization workflow for a 12-row variant table (FILTER, DP, GQ, AF, CONSEQUENCE, CLINVAR_SIG). Give me the ordered filter steps and thresholds first, with justification for each, before any code. Then implement it in R using the provided starter skeleton — but I will not accept any threshold I have not chosen myself."

我运行了该 workflow (R 骨架逻辑已复现并执行; 脚本见附录): 12 个变异 $\rightarrow$ FILTER=PASS (10) $\rightarrow$ DP $\geq$ 20 且 GQ $\geq$ 30 (9) $\rightarrow$ AF $\leq$ 0.01 (6) $\rightarrow$ 高/中影响后果 (4) $\rightarrow$ 短名单: TP53、BRCA2、KRAS、LDLR $\rightarrow$ 按 ClinVar 权重 + 稀有度排序:

表 5 Q4 筛选短名单 (按 ClinVar 权重与稀有度排序)

排名	变异	为什么保留
1	chr17:7673803 G>A TP53 splice_acceptor	Pathogenic 注释、AF 1e-5 (极稀有)、QC 优秀 (DP 80, GQ 99)

排名	变异	为什么保留
2	chr13:32316461 C>T BRCA2 missense	稀有（AF 1e-4）、QC 好、已确立疾病基因中的 VUS——需要随访
3	chr12:25398284 C>A KRAS missense	稀有、注释冲突——观察名单
4	chr19:11200200 C>T LDLR missense	稀有但可能良性——最低优先级

被过滤逻辑刻意排除的：MSH2 stop_gained 与 MECP2 frameshift 看起来“很严重”，但技术 QC 不合格（LowQual/DP8/GQ12 与 DP5/GQ20）——注释惊人而 call 不可靠正是经典的假线索；F5/ATM/chr4 为常见等位基因，CFTR 同义与基因间变异则按频率或后果被过滤。

3. 验证（权威来源）

每个保留的 call 都使用至少两个权威资源（由于本表为合成数据，验证的是流程）：

ACMG/AMP 2015 分类框架（Richards 等，*Genet Med* 17:405–424，2015）——五级术语（pathogenic...benign）与证据规则：LOF 机制基因中的经典剪接受体位点变异可获 PVS1；极低 AF 支持 PM2；ClinVar 标签只是声明而非证明——实验室必须按 ACMG 标准重新分类。
ClinVar（ncbi.nlm.nih.gov/clinvar）——核对记录、提交者数量、审核状态、是否存在冲突提交。
gnomAD（gnomad.broadinstitute.org）——人群 AF：1e-5–1e-4 为稀有/缺失，符合稀有病假说；AF 0.18–0.42 属常见，与严重单基因表型不相容（BA1/BS1）。
Ensembl VEP / NCBI RefSeq——对照转录本坐标确认后果注释（splice_acceptor vs missense）。
PubMed——任何临床解读前先核对基因–表型匹配（TP53 → Li-Fraumeni 谱系；BRCA2 → 遗传性乳腺卵巢癌综合征等）。

4. 最终结论

首选 1–2 个变异及理由。(1) chr17:7673803 G>A（TP53, splice_acceptor_variant, Pathogenic, AF 1e-5, DP 80/GQ 99, PASS）：唯一一个通过全部硬过滤、且具有高影响后果、极稀有频率与一致致病注释的变异——最高优先级。(2) chr13:32316461 C>T（BRCA2, missense, VUS, AF 1e-4, DP 60/GQ 90, PASS）：已确立疾病基因中的稀有高质量 VUS——家系共分离与功能随访的标准候选。KRAS（冲突注释）列入观察名单；LDLR（可能良性）降权。

假阳性批判（让 AI 攻击首选 call）。

表 6 Q4 假阳性批判

AI 提出的担忧	科学上重要？（Y/N）	为什么
----------	-------------	-----

AI 提出的担忧	科学上重要？（Y/N）	为什么
“Pathogenic”只是合成表中的断言——真实 ClinVar 记录可能不一致	Y	ClinVar 条目可能存在冲突提交与不同审核状态；任何结论前必须复核
剪接效应只是预测、未经证实	Y	splice-acceptor 注释是 后果预测 ；没有 RNA/细胞学证据，实际剪接结局（外显子跳跃、无义介导降解、渗漏剪接）未知——这是决定性的不确定性
表型-基因匹配未知	Y	只有临床表型符合 TP53 相关（Li-Fraumeni 样）谱系时 TP53 才相关；本表没有表型
AF 1e-5 可能是单一人群的伪影	部分	值得检查祖先特异频率；但 1e-5 与真实稀有致病变异相容
高深度（DP 80）保证 call 正确	N	深度只保护基因型，不保护生物学解读——不要过度加权

我接受为剩余风险的担忧：未经证实的剪接效应与缺失的表型——这两项是后续实验/临床步骤，而不是丢弃该变异的理由。

约 200 词解读（已知证据 → 计算推断 → 科学假设 → 所需实验）。

已知证据： 变异表报告 chr17:7673803 G>A 为 PASS、超深（DP 80, GQ 99）、极稀有（AF 1e-5）的 TP53 剪接受体位点变异，带“Pathogenic”式 ClinVar 标签。**计算推断：** 我的过滤链（技术 QC → 深度/GQ → 人群频率 → 后果 → 临床标签）把这个变异保留为唯一最高排名候选；同一链条排除了两个表面严重的 call（MSH2 stop-gained、MECP2 frameshift），因为技术质量低到不可信，也排除了常见等位基因（F5、ATM），因为频率排除其严重单基因致病角色。**科学假设：** 该变异破坏 TP53 的经典剪接受体位点，导致异常剪接、功能 p53 减少或缺失——若表型匹配，则与 TP53 相关（Li-Fraumeni 样）易感一致。**所需实验：**（i）用正交临床检测复核变异并按 ACMG/AMP 重新分类；（ii）用 RNA 证据证明剪接缺陷（携带者组织 RT-PCR/捕获 RNA-seq，或 minigene 剪接检测）；（iii）下临床结论前确立表型-基因匹配与家系共分离。表格的合成性质意味着交付物是 **workflow 本身**，而非临床声明。




图 4 Q4 变异优先级 workflow

变异 chr17:7673803 G>A (TP53) 可能通过破坏经典剪接受体位点、从而影响前体 mRNA 剪接 (功能性 p53 缺失) 来影响 TP53 功能; 这可以通过 RNA 剪接检测 (携带者材料 RT-PCR / 捕获 RNA-seq, 或 minigene 剪接检测) 加正交复核与临床实验室 ACMG 分类来检验。

参考文献

- [1] Buenrostro JD, et al. Transposition of native chromatin for fast and sensitive epigenomic profiling of open chromatin, DNA-binding proteins and nucleosome position. *Nat Methods* 10:1213–1218 (2013). doi:10.1038/nmeth.2688.
- [2] Kaya-Okur HS, et al. CUT&Tag for efficient epigenomic profiling of small samples and single cells. *Nat Commun* 10:1930 (2019). doi:10.1038/s41467-019-09982-5.
- [3] Creighton MP, et al. Histone H3K27ac separates active from poised enhancers and predicts developmental state. *PNAS* 107:21931–21936 (2010). doi:10.1073/pnas.1016297108.
- [4] Andersson R, et al. An atlas of active enhancers across human cell types and tissues. *Nature* 507:455–461 (2014). FANTOM5. <https://fantom.gsc.riken.jp/5/>
- [5] Melnikov A, et al. Systematic dissection and optimization of inducible enhancers in human cells using a massively parallel reporter assay. *Nat Biotechnol* 30:271–277 (2012). doi:10.1038/nbt.2137.
- [6] Fulco CP, et al. Systematic mapping of functional enhancer–promoter connections with CRISPR interference. *Science* 354:769–773 (2016). doi:10.1126/science.aag2446.
- [7] GATK Best Practices — germline short variant discovery; HaplotypeCaller documentation. <https://gatk.broadinstitute.org/hc/en-us/articles/4404604697243-HaplotypeCaller>
- [8] Schneider VA, et al. Evaluation of GRCh38 and de novo haplotypes. *Genome Res* 27:849–864 (2017).
- [9] FastQC (Babraham Bioinformatics). <https://www.bioinformatics.babraham.ac.uk/projects/fastqc/>
- [10] Nasser J, et al. Genome-wide enhancer maps link risk variants to disease genes. *Nat Genet* 53:354–366 (2021). doi:10.1038/s41588-021-00791-3.
- [11] Hsieh T-HS, et al. Resolving the 3D landscape of transcription-linked mammalian chromatin folding. *Mol Cell* 78:539–553 (2020).
- [12] Richards S, et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of ACMG and AMP. *Genet Med* 17:405–424 (2015). doi:10.1038/gim.2015.30.
- [13] ClinVar, NCBI. <https://www.ncbi.nlm.nih.gov/clinvar/>
- [14] gnomAD. <https://gnomad.broadinstitute.org/>; Gudmundsson S, et al. Variant interpretation using population databases: Lessons from gnomAD. *Hum Mutat* (2022). doi:10.1002/humu.24309.
- [15] Ensembl VEP. <https://www.ensembl.org/info/docs/tools/vep/index.html>

附录

使用的提示词（摘要）

- Q1: "critique my ATAC-first assay decision tree — what can each assay measure and not prove, what order would you test, don't replace my design."
- Q2: "plan-first: ordered WGS steps + purpose + software + formats; only then concrete commands; then audit my chosen QC metrics."
- Q3: "separate direct observation vs biological interpretation vs missing evidence for each of five omics layers; strongest alternative to 'it is Gene Y's enhancer'; one causal experiment."
- Q4: "plan-first filter steps with thresholds and justification, then implement in R with my thresholds; afterwards, give the strongest reasons my top variant could be a false lead."

代码 / 阈值

- Q4 分析（已执行，结果见正文）：`data/q4_filter_analysis.py` —— 阈值 $DP \geq 20$ 、 $GQ \geq 30$ 、 $AF \leq 0.01$ 、 $FILTER=PASS$ 、后果 $\in \{stop_gained, frameshift, splice_acceptor, splice_donor, missense\}$ ；短名单 `data/q4_shortlist_myfilters.tsv`（也可用 `starter/q4_filter_starter.R` 填入上述阈值复现）。
- Q2 demo 核验：`data/q2_demo_fastq_check.py` —— 120 条 $PE \times 80$ bp；18/120（15%）含接头；高 GC spike；重复模板；3' 质量下降 —— 与 `fastqc_snapshot.tsv` 一致。
- 图生成：`make_figures.py`（可复现全部 4 张图）。